

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO
FAKULTETA ZA MATEMATIKO IN FIZIKO

Miha Maksimiljan Bertoncelj

**Samodejna segmentacija krošenj
dreves v LiDAR podatkih: primerjava
klasičnih in nevronskih metod**

DIPLOMSKO DELO

INTERDISCIPLINARNI UNIVERZITETNI
ŠTUDIJSKI PROGRAM PRVE STOPNJE
RAČUNALNIŠTVO IN MATEMATIKA

MENTOR: doc. dr. Ciril Bohak

Ljubljana, 2025

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 4.0 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema je ponujena pod licenco MIT. To pomeni, da se lahko prosto uporablja, kopira, spreminja, združuje, objavlja, distribuira, podlicencira in/ali prodaja kopije programske opreme, pod pogojem, da je v vseh kopijah ali pomembnih delih programske opreme priložen izvirni avtorski in licenčni zapis. Besedilo celotne licence je dostopno na spletni strani <https://opensource.org/licenses/MIT>. Izvorna koda je dostopna na repozitoriju GitHub: https://github.com/mihaMaks/Segmentacija_dreves.

Besedilo je oblikovano z urejevalnikom besedil $\LaTeX$.

Kandidat: Miha Maksimiljan Bertoncej

Naslov: Samodejna segmentacija krošenj dreves v LiDAR podatkih: primerjava klasičnih in nevronske metode

Vrsta naloge: Diplomski naloga na univerzitetnem programu prve stopnje Računalništva in matematike

Mentor: doc. dr. Ciril Bohak

Opis:

Študent naj v okviru diplomskega dela pregleda obstoječe pristope za segmentacijo posameznih dreves iz LiDAR podatkov in ortofoto posnetkov. Nadalje naj zasnuje način označevanja podatkov za učenje globokih modelov, pri čemer naj uporabi dva pristopa: (1) očrtani krogi posameznih krošenj in (2) maske, pridobljene z metodo za segmentacijo poljubnih objektov. Na ta način naj pripravi učne podatke za primerjavo sodobnih metod globokega učenja, kot je SegmentAnyTree, s klasičnimi pristopi segmentacije. Poseben poudarek naj bo na ovrednotenju kakovosti pripravljenih anotacij. Rezultate naj predstavi in primerja z obstoječimi GIS podatki ter jih kvantitativno in kvalitativno ovrednoti.

Title: Automatic tree canopy segmentation in LiDAR data: a comparison of classical and neural methods

Description:

As part of the thesis, the student should review existing approaches for segmenting individual trees from LiDAR data and orthophoto images. Furthermore, they should design a method of labeling data for training deep models, using two approaches: (1) outlined circles of individual crowns and (2) masks obtained with the segment anything method. In this way, they should prepare training data for comparing modern deep learning methods, such

as SegmentAnyTree, with classic segmentation approaches. Special emphasis should be placed on evaluating the quality of the prepared annotations. The results should be presented and compared with existing GIS data and evaluated quantitatively and qualitatively.

V prvi vrsti se zahvaljujem mentorju za ves posvečen čas ter za njegovo dosgljivost. Hvaležen sem tudi svoji družini, ki me vedno podpira, in na koncu še cimru za vse skuhane kave ter Vanji za moralno podporo.

Kazalo

Povzetek

Abstract

1	Uvod	1
2	Pregled področja	3
3	Uporabljene metode	7
3.1	Nevronske mreže	7
3.2	SegmentAnyTree	11
3.3	Pycrown	13
4	Priprava podatkov	15
4.1	Priprava podatkov	15
5	Rezultati	19
5.1	Metrike za oceno uspešnosti metod	19
5.2	Razprava	23
6	Zaključek	31
	Literatura	33

Seznam uporabljenih kratic

kratica	angleško	slovensko
SPD	individual tree segmentation	segmentacija posameznih dreves
PC	point cloud	oblak točk
VMK	canopy height Model	višinski model krošenj
NOT	normalized point cloud	normaliziran oblak točk
DMR	digital terrain model	digitalni model reliefa
DMP	digital surface model	digitalni model površja
POF		popolni ortofoto
CRS	coordinate reference system	koordinatni referenčni sistem
ZGS		Zavod za gozdove Slovenije
PPV	positive predictive value	pozitivna napovedna vrednos
FNR	false negative rate	stopnja lažno negativnih primerkov
FDR	false discovery rate	stopnja lažnih odkritij
TPR	true positive rate	stopnja pozitivnih primerkov
PP	true positives	število pravilno pozitivnih primerkov
NN	false negatives	število napačnih negativnih primerkov
NP	false positives	število napačno pozitivnih primerkov
RMSE	root mean squared error	koren srednje kvadratne napake
SAT	SegmentAnyTree	

Povzetek

Naslov: Samodejna segmentacija krošenj dreves v LiDAR podatkih: primerjava klasičnih in nevronske metode

Avtor: Miha Maksimiljan Bertonec

Ocena gozdnega stanja nam daje pomembne podatke o zdravstvenem stanju in biotski raznovrstnosti gozda. Obenem je dolgotrajen proces, ki ga je treba redno izvajati. V diplomskem delu smo raziskali metode segmentacije posameznih dreves iz LiDAR podatkov, ki bi proces poenostavile in pohitrile. Testirali smo dve že razviti metodi segmentacije. Prva je temeljila na tvorjenju VMK (angl. Canopy height model) in rasti regij (angl. region growing). Druga je uporabljala model globokega učenja in se naslanja na arhitekturo U-Net. Metodi smo testirali na naših podatkih. Metodi sta dosegli 77 % natančnost. Pokazali smo, da je metoda globokega učenja uspešnejša za segmentacijo nižjih dreves in gostih iglastih gozdov. Utemeljili smo potencial globokega učenja za obravnavano nalogo.

Ključne besede: segmentacija dreves, lasersko skeniranje, oblak točk, konvolucijske mreže.

Abstract

Title: Automatic tree canopy segmentation in LiDAR data: a comparison of classical and neural methods

Author: Miha Maksimiljan Bertonec

Assessment of forest condition provides important information about the health status and biodiversity of the forest. At the same time, it is a long-lasting process that needs to be carried out regularly. In this thesis, we investigated methods for segmenting individual trees from LiDAR data, which could simplify and accelerate the process. We tested two already developed segmentation methods. The first was based on generating a Canopy Height Model (CHM) and region growing. The second used a deep learning model and was based on the U-Net architecture. Both methods were tested on our dataset. The methods achieved an accuracy of 77 %. We showed that the deep learning method is more successful for the segmentation of smaller trees and dense coniferous forests. We substantiated the potential of deep learning for the considered task.

Keywords: tree segmentation, laser scanning, point cloud, convolutional neural networks.

Poglavje 1

Uvod

Daljinsko zaznavanje se z razvojem sodobnih tehnologij hitro razvija in postaja vse pomembnejše na različnih področjih industrije in znanosti. Med metodami, ki omogočajo natančno analizo prostora, ima posebno mesto tehnologija LiDAR.

LiDAR (angl. Light Detection and Ranging), oziroma svetlobno zaznavanje in merjenje, je geodetska metoda za merjenje razdalje do tarče s pomočjo laserskih žarkov. Tehnologija se pogosto uporablja za izdelavo visokokakovostnih zemljevidov in ima širok spekter aplikacij v geodeziji, geomatiki, arheologiji, geografiji, geologiji, geomorfologiji, seizmologiji, gozdarstvu in drugih vedah. Zaradi načina delovanja se LiDAR včasih imenuje tudi lasersko ali 3D-skeniranje. Z uporabo laserskih impulzov in globalnega sistema pozicioniranja (GPS) senzor zajema podatke o točkah na zemeljskem površju, iz katerih je mogoče ustvariti trirazsežen oblak točk (angl. point cloud). Ti oblaki točk predstavljajo osnovno enoto za nadaljnjo analizo in obdelavo.

Pridobljeni podatki omogočajo razvoj novih metod zaznavanja ter analize oddaljenih in težko dostopnih območij. Primer takšne uporabe je analiza Marsovega površja, ki jo je omogočil instrument MOLA na sondi Mars Global Surveyor [24]. LiDAR je nepogrešljiv tudi v razvoju avtonomnih vozil, kjer zagotavlja natančno zaznavanje okolice. Prav ta natančnost je ključna tudi pri raziskovanju naravnih ekosistemov, kjer tradicionalne metode merjenja

pogosto niso dovolj učinkovite. V zadnjem desetletju je zato LiDAR postal eno najpomembnejših orodij pri analizi gozdov, saj omogoča celovit vpogled v njihovo strukturo, gostoto in dinamiko rasti.

Razumevanje gozdne inventure je ključno za oceno trenutnega stanja gozdnih virov, spremljanje sprememb ter za prepoznavanje ekoloških koristi gozdov. Prav tako je pomembno za učinkovito varovanje in trajnostno upravljanje gozdnih ekosistemov [15]. Vodenje evidence gozdne inventure je zamuden in dolgotrajen proces, pri čemer dodatne izzive predstavlja analiza oddaljenih ali težko dostopnih območij. V tej nalogi bomo raziskali nov pristop za analizo gozdne inventure na podlagi segmentacije posameznih dreves (angl. Individual Tree Detection, v nadaljevanju SPD). Namen dela je primerjava dveh metod: referenčne metode, ki temelji na klasičnih pristopih, kot so rasterizacija in iskanje lokalnih maksimumov ter nove metode, ki temelji na uporabi nevronske mreže. Cilji naloge so naslednji:

- ovrednotiti delovanje obeh metod na podatkih, zajetih v Sloveniji,
- prikazati in analizirati rezultate,
- preveriti učinkovitost metod tudi na manj kakovostnih podatkih.

V naslednjem poglavju bomo bralcu najprej predstavili problematiko ter naredili kratek pregled obstoječih pristopov za SPD, ki so se razvijali skozi čas. V poglavju 3 bomo podrobneje opisali uporabljeni metodi in osnovne pristope, na katerih temeljita. V poglavju 4 sledi predstavitev postopkov priprave podatkov, ki so bili uporabljeni pri razvoju in vrednotenju obeh metod SPD. Opišemo obdelavo osnovnih virov (LiDAR, digitalni modeli in ortofoto posnetki) ter pripravo podatkovnih slojev, primernih za anotacijo in nadaljnjo analizo. Na koncu predstavimo rezultate naloge in podamo smernice za nadaljnje raziskave.

Poglavje 2

Pregled področja

Naloga SPD je odvisna od več dejavnikov, ki lahko različno vplivajo na metode segmentacije dreves. V preteklosti je bilo izvedenih veliko študij [17, 33, 30, 7] tako na homogenih kot heterogenih gozdovih, pri čemer homogeni gozdovi predstavljajo drevesa ene vrste, heterogeni pa mešanico različnih vrst. Sama sestava gozda in gostota rasti imata ključen vpliv na uspešnost metod. Prav tako je pomembno, ali analiziramo eno-slojni gozd ali več-slojni gozd. Metode običajno eno-slojni gozd segmentirajo z večjo natančnostjo kot več-slojnega [8].

Nekateri pristopi poleg LiDAR podatkov uporabljajo tudi barvne in NIR (angl. Near-Infrared) posnetke, kar lahko izboljša zaznavanje dreves. Pri primerjavi metod moramo biti pozorni tudi na kakovost oziroma gostoto 3D oblaka točk (angl. point cloud, PC), ki jih generiramo iz LiDAR posnetkov [26].

Segmentacija dreves iz podatkov LiDAR je bila predmet raziskav že pred letom 2000. Prvi pristopi so se osredotočali na optične slike [23]. Kasnejši pristopi so pogosto uporabljali rasterizacijo oblaka točk v višinski model krošenj, VMK (angl. canopy height model, CHM). Na njem temeljijo metode, kot so iskanje lokalnih maksimumov (angl. local maxima) [19, 14], prilagoditvena binarizacija (adaptive binarization) [20], različne oblike algoritma za rast regij (region-growing) [16, 4, 32], detekcijo robov (edge detection) [27] in sledenje dolinam (valley-following) [9].

Pri tovrstnih metodah na rezultate močno vpliva izbira parametrov algoritma, kar pomeni, da se lahko metoda slabše obnese v gozdovih z različno gostoto in strukturo. Poleg tega je izbira dobrih parametrov težavna in zahteva dobro analizo strukture gozda. Med ključne pomanjkljivosti rasterizacije sodi pretvorba izvornih 3D podatkov v 2D, pri čemer se del informacij izgubi [31].

Drugi pristopi temeljijo na normaliziranem oblaku točk (NOT), kjer se drevesa segmentirajo neposredno na osnovi informacij, ki jih zajemajo.

Primerjava metode, ki temelji na rasterizaciji in metode, ki neposredno uporablja NOT [11], je pokazala, da obe zanesljivo zaznata dominantna drevesa, medtem ko se zaznavna stopnja (angl. detection rate) pri zatrtih in odmrlih drevesih občutno zmanjša. Poleg tega pri metodi, ki temelji na oblaku točk, pogosteje privede do podsegmentacije (spregleda drevesa), medtem ko metoda, ki temelji na VMK, vodi v nadsegmentacijo oz. segmentira preveč dreves.

Izboljšavo na drevesih z manj vidno krošnjo je pokazala metoda slojevitega zlaganja (angl. layer stacking) [2]. Metoda oblak točk razreže na višinske sloje velikosti enega metra. Iz vsakega sloja izolira drevesa, kar ji omogoča segmentacijo posameznih dreves. Izkazala se je predvsem na segmentaciji listavcev, sicer pa stopnja napačnih segmentacij ni bila dosti boljša od predhodnih metod.

Kljub obilici raziskav na temo segmentacije posameznih dreves, trenutna raven razvoja (SOTA – state of the art) algoritmov za detekcijo in segmentacijo dreves ni veliko napredovala. Primerjava dveh obsežnih mednarodnih primerjalnih študij (Kaartinen et al., 2012 [12]; Cao et al., 2023 [3]) je pokazala zgolj majhne izboljšave v metrikah kot so stopnje zaznavanja ali F1-indeks. Obe raziskavi sta izpostavili nizke stopnje zaznavanja (v povprečju 52 %), predvsem zaradi slabe detekcije ko-dominantnih dreves (tj. dreves v zgornji plasti, ki stojijo zelo blizu skupaj) ter izrazito slabe detekcije zatiranih oziroma podrastnih dreves (tj. dreves, ki jih povsem zakriva zgornja krošnja in niso vidna od zgoraj).

Z razvojem zmogljivejših računalnikov se je tudi časovna zahtevnost segmentacije iz oblaka točk zmanjšala. Vedno bolj so aktualne tudi metode, ki temeljijo na učenju globokih nevronske mreže. Najnovejši pristopi, ki temeljijo na globokem učenju, kažejo velik potencial, saj odpravljajo potrebno po nastavitvi parametrov in omogočajo prenosljivost med različnimi gozdni tipi. Najboljše rezultate dosegajo na zelo gostih podatkih terenskega laserskega skeniranja (terrestrial laser scanning, TLS) in zračnega laserskega skeniranja (angl. arial laser scanning, ALS). Na redkejših oblakih točk uporaba takih metod še vedno predstavlja izziv.

Metode ForAiNet [29], TreeLearn [10] in SegmentAnyTree [28] so bile razvite pred kratkim in dosegajo dobre rezultate na javnih podatkovnih bazah za SPD. Prvi dve metodi sta sicer zasnovani za segmentacijo gostih oblakov točk, kar ni optimalno za naše podatke. Nasprotno je bila metoda SegmentAnyTree [28] (v nadaljevanju SAT) posebej razvita za uporabo na redkejših podatkih, kar jo naredi primerno za našo analizo.

Poglavje 3

Uporabljene metode

V tem poglavju opisujemo metode, ki jih uporabljamo pri pristopu za segmentacijo posameznih dreves. Najprej predstavimo delovanje konvolucijskih nevronske mreže. Nato bolj podrobno opišemo arhitekturo uporabljenega modela v tem delu in delovanje referenčnega algoritma za segmentacijo.

3.1 Nevronske mreže

Nevronske mreže so poseben tip modelov strojnega učenja, poimenovane po strukturi nevronskega omrežja iz biologije [22]. Nevronske mreže vsebujejo več plasti, kjer vsako plast sestavljajo nevroni. Plasti so med seboj povezane, in sicer tako, da je vsak nevron v plasti povezan z vsemi ali nekaterimi nevroni predhodne in naslednje plasti. Ko se informacije premikajo iz ene v drugo plast, se v vsakem koraku aktivirajo nekateri od nevronov, kar nam omogočajo aktivacijske funkcije. Vsaka povezava med nevroni ima svojo utež, ki določa, kako močno bo signal prenesen naprej. Skupaj z utežmi imajo nevroni tudi pristranskost, ki dodatno uravnava prag aktivacije.

Delovanje mreže poteka v dveh glavnih fazah: propagacija naprej in učenje z vzratnim razširjanjem napake (angl. backpropagation). Pri propagaciji naprej mreža za dane vhodne podatke postopoma izračuna izhod. Napako med napovedanim in dejanskim izhodom nato uporabimo za pril-

goditev uteži s pomočjo optimizacijskih algoritmov, kot je gradientni spust. S ponavljanjem tega procesa se mreža postopno uči prepoznavati vzorce in izboljšuje svoje napovedi. Cilj nevronske mreže je torej, da iz vhodnih podatkov ustvari pravilne in uporabne izhode.

3.1.1 3D konvolucijska nevronska mreža


3D konvolucijske nevronske mreže (angl. 3D Convolutional neural networks, 3D CNN) so vrsta globokih modelov za strojno učenje, namenjenih obdelavi in segmentaciji tridimenzionalnih podatkov kot so medicinske volumetrične slike (npr. CT, MRI) ali oblaki točk, zajetih s tehnologijo LiDAR. Mreže delujejo na tridimenzionalnih podatkih in so zasnovane tako, da zajamejo prostorske odvisnosti podatkov. Te prostorske odvisnosti mreža obdeluje s pomočjo vokselizacije vhodnih podatkov (angl. voxelization) [1].

Voksel

Voksel je osnovni volumetrični podatek v 3D prostoru, analog piksla v 2D prostoru. Voksel je navadno definiran na tridimenzionalni regularni mreži. Podaja informacije o svojem položaju v trirazsežnem prostoru in dodatne lastnosti, kot so intenziteta laserskega odboja, število oblakovnih točk v njem ali kot skeniranja (angl. scan angle). Kadar voksel ne vsebuje nobene točke rečemo, da je prazen. Voksle, ki vsebujejo eno ali več točk, bomo imenovali aktivni vokslji. Voksli rešujejo več problemov, ki se pojavijo pri obdelavi oblakov točk. Z njimi lažje in hitreje izvajamo operacije, ki jih uporabljamo v nevronskih mrežah.

3.1.2 Konvolucijski sloji in funkcije

3D CNN uporabljajo tridimenzionalne konvolucijske sloje, na katerih se izvajajo različne operacije. Poleg konvolucije se uporabljajo tudi združevalni sloji z maksimizacijo (angl. max-pooling), sloji za zmanjševanje prostorskih razsežnosti, aktivacijske funkcije za vpeljevanje nelinearnosti ter preskočne



Slika 3.1: Primer delovanja maksimizacijskega sloja

povezave (angl. skip connections), ki omogočajo prenos informacij iz nižjih plasti v višje plasti mreže.

Združevalni sloj z maksimizacijo

Združevalni sloj z maksimizacijo 3.1 je ena od osnovnih operacij v konvolucijskih nevronske mrežah (CNN) in se uporablja za zmanjšanje razsežnosti podatkov, ki hkrati ohranja njihove najpomembnejše značilnosti. Vhodni podatek takega sloja je matrika, ki ji rečemo nabor značilk (angl. feature map). Ta matrika se razdeli na manjša okna. Iz njih se ustvari nova matrika, tako da iz vsakega okna ohranimo le največji element.

$$Y_{i,j} = \max\{X_{m,n} \mid m \in [i \cdot p, i \cdot p + p - 1], n \in [j \cdot p, j \cdot p + p - 1]\}$$

Kjer:

- X je vhodna matrika
- Y je izhod po združevanju
- $p \times p$ je velikost okna za združevanje.

Konvolucija

Konvolucija se uporablja za izluščanje značilnosti iz vhodnih podatkov (npr. slika, oblak točk), kot so robovi, teksture, oblike. Konvolucijo izvedemo tako, da čez vhodno matriko drsimo s filtrom (angl. kernel) in na vsakem koraku pomnožimo istoležne elemente, jih seštejemo ter zapišemo v izhodno matriko.

$$(S * K)_{i,j} = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} S_{i+m,j+n} K_{m,n}$$

Kjer:

- S je vhodna matrika,
- K je jedro (filter) velikosti $M \times N$,
- i, j sta koordinati elementa izhoda.

Preskočne povezave


Preskočne povezave so posebne povezave v nevronske mrežah, kjer informacijo iz prejšnje plasti neposredno prenesemo v kasnejšo plast. To nam omogoča prenos finih prostorskih informacij iz začetnih slojev v poznejše sloje.

Dekonvolucija

Dekonvolucija je operacija, ki nasprotno od klasične konvolucije poveča razsežnost podatkov. To dosežemo tako, da elemente vhodne matrike razmaknemo in dodamo ničelne vrednosti. Nad tako matriko nato naredimo konvolucijski korak. Rezultat je večja matrika.

Podmnogoterčna redka konvolucija

Ker imamo opravka s podatki velikih obsegov, je lahko konvolucija časovno zahtevna operacija. Podmnogoterčna redka konvolucija (angl. sub-manifold sparse convolution) to težavo rešuje tako, da se konvolucija, v primeru 3D




Slika 3.2: U-Net arhitektura

vokselizacijske mreže, izvaja samo na aktivnih voksljih, kar pohitri postopek. Klasična konvolucija na redkih podatkih, na primer aktivnem vokslju, ki ima v okolici samo prazne voksele, bi aktivirala tudi prazne voksele. To bi lahko privedlo do zapolnitve praznin. To je za namen metode neoptimalno. Podmnogoterčna konvolucija ta problem prepreči tako, da ne aktivira novih voksllov.

3.2 SegmentAnyTree

Model predstavljen v tem delu, je bil razvit kot izboljšava zgoraj omenjenih problemov, slaba robustnost za različne tipe gozdov in nezaznavnje dreves v podrastu.

Model SegmentAnyTree je prevzel arhitekturo in implementacijo modela za segmentacijo primerkov v velikih oblakih točk, ki jo je predlagal Xiang et al. (2023) [29]. Metoda se naslanja na arhitekturo U-Net [21] (na sliki 3.2), ki iz voksaliziranega oblaka točk izlušči vektorje značilnosti. Model zagotovi prenos teh značilnosti z uporabo preskočnih povezav omenjenih zgoraj. To ohranja integriteto visoko in nizko slojnih značilnosti skozi vso mrežo. Nato se proces razdeli na tri enote. Prva enota je za semantično segmentacijo (drevo ali ne-drevo). Ta enota uporablja večplastni perceptron (angl. multi-



Slika 3.3: Arhitektura modela SegmentAnyTree

layer perceptron MLP) za izračun verjetnosti pripadnosti razredu. Ostali dve enoti sta namenjeni naslednjim vdelavam za segmentacijo primerkov.

Ena napoveduje 3D odmik (angl. offset) vektorja, ki vsako točko premakne proti središču njenega drevesa, kar omogoča gručenje točk, ki pripadajo istemu drevesu. Druga točke preslika v 5-dimenzionalni vdelani prostor, v katerem se točke istega drevesa gručijo skupaj, medtem ko so točke različnih dreves med seboj ločene.

Nato se dobljene vdelave združijo v kandidate posameznih dreves z uporabo algoritma rasti regij (angl. region-growing) in premik povprečja (angl. mean-shift). Te kandidate dodatno obdela ScoreNet [25], nevronska mreža, ki filtrira in združuje kandidate na podlagi njihove prekrivnosti (IoU) s podatki zlatega standarda (angl. ground truth). Model je treniran v enotnem postopku učenja (angl. end-to-end) z uporabo kombinirane funkcije izgube, ki vključuje semantično izgubo, izgubo usmerjenosti, regresijsko izgubo in izgubo ocene. Med napovedjo (angl. inference) se nad dobljenimi gručami izvede izločanje nemaksimalnih vrednosti (angl. non-maximum suppression) na podlagi napovedanih ocen ScoreNet-a, s čimer se seznam kandidatov očisti in se izpišejo končne napovedi segmentacije posameznih dreves [28].

V učnem procesu modela je bilo uporabljenih tudi več dodatnih postopkov za povečanje robustnosti podatkov (angl. data augmentation). Dodan je bil šum s $\sigma = 0.01$ m, ki rahlo premakne podatkovne točke ter s tem posnema merilne napake senzorja ali okoljske motnje, značilne za 3D skeniranje. To poveča odpornost modela na manjše nedoslednosti podatkov in

zmanjša odvisnost od visoko kakovostnih meritev. Uporabljeno je bilo naključno anizotropno skaliranje (s faktorjem med 0.9 in 1.1) ter naključne simetrije, kjer se podatki preslikajo prek izbranih osi. Na ta način se model nauči prepoznavati objekte tudi ob spremembah velikosti in različnih simetričnih orientacijah. Vsi hiperparametri so bili nespremenjeni skozi vse testne scenarije [28].

3.3 Pycrown

Sledečo metodo smo uporabili kot referenčno metodo. Metoda deluje na principu rasterizacije, iskanju lokalnih ekstremov in odločitvenih dreves. Razvita je bila za namen napovedovanja gostote ogljika v gozdu z določanjem in napovedjo velikosti krošenj posameznih dreves [6]. V nadaljevanju najprej predstavimo osnovne pojme, ki so pomembni za delovanje metode.

Rasterizacija

Rasterizacija je postopek pretvorbe oblaka točk v dvorazsežno mrežo celic. Vsaka celica vsebuje pridružen podatek, izluščen iz točk kot so povprečna višina točk ali najvišja točka.

Normaliziran oblak točk

Normaliziran oblak točk (NOT) je nov oblak točk, ki ga dobimo tako, da od vrednosti višine točke Z_i odštejemo vrednost višine Z_{0i} točke tal, ki je v ravninski projekciji najbližja obravnavani točki. Višinska vrednost v najnižji točki je 0, višine drugih točk pa odražajo višino krošnje [15].

Model višine krošenj

VMK je rastrska predstavitev razdalje od tal do najvišje strukture krošnje vegetacije. Poenostavljen postopek generiranja VMK lahko bomo opisali v nadaljevanju. Najprej se ustvari NOT z izračunom razdalje med digitalnim

modelom reliefa, DMR, in najvišjo višinsko vrednostjo LiDAR točk v vsakem pikslu. Nato se VMK ustvari s tem, da se višina na območjih brez gozda nastavijo na nič [18]. Na območjih gozda se vrednosti pikslov lahko izračunajo na več načinov. Za posamezno vrednost piksla lahko uporabimo npr. povprečje višine točk NOT ali kar višino najvišje točke v pikslu.

3.3.1 Algoritem

Referenčna metoda najprej zgladi VMK z gladilnim filtrom velikosti 5 m . Za funkcijo glajenja se uporabi mediana vrednosti sosednjih pikslov. Na zglajenem VMK poišče lokalne maksimume z drsečim oknom in višinskim pragom 11 m . Lokalni ekstremi služijo kot zrna (angl. seeds) za segmen-tiranje krošenj. Zrna so določena kot drevesni vrhovi, iz katerih se izvede metoda rasti posameznih krošenj po naslednjih korakih:

1. Vsak lokalni maksimum se označi kot začetna regija, okoli katere lahko zraste krošnja.
2. Višine štirih sosednjih pikslov se pridobijo iz VMK. Pikel se doda v regijo, če je njegova navpična razlika od lokalnega maksimuma manjša od uporabniško določenega odstotka višine maksimuma in manjša od uporabniško določene maksimalne razlike.
3. Ta postopek se iterativno ponavlja za vse sosednje pikse, ki so že vključeni v regijo, dokler ni mogoče dodati novih pikslov.
4. Za vsako identificirano regijo se izločijo prve refleksne točke ALS (angl. first-return ALS points), pri čemer se najprej odstranijo nizko ležeče točke.
5. Na dobljenih točkah se uporabi 2D konveksna ovojnica (angl. convex hull). Rezultat postanejo končne poligonske oblike posameznih drevesnih krošenj.

Poglavje 4

Priprava podatkov


Za poročilo smo podatke pridobili iz spletnega portala Ciklično lasersko skeniranje Slovenije¹. Portal nam omogoča dostop do georeferenciranih in klasificiranih oblakov točk, digitalnega modela površja (DMP), digitalnega modela reliefa in popolnih ortofoto slik (POF).

Uporabili smo podatke iz gozdno gospodarskega območja Bled v letu 2023. Vsi podatki, uporabljeni v tej študiji, so bili zajeti na območju, omejenem s koordinatami 434 000 m do 435 000 m v smeri vzhod (Easting) in 128 000 m do 129 000 m v smeri sever (Northing). Zajeti podatki so bili pridobljeni z digitalnim senzorjem RIEGL VQ-780IIS. Za natančno prostorsko referenciranje so podatki zapisani v koordinatnem referenčnem sistemu (CRS) EPSG:3794, ki omogoča pravilno interpretacijo geometrije in medsebojno primerljivost s podatki drugih virov.

4.1 Priprava podatkov

Pridobitev natančnih podatkov o lokacijah in velikostih drevesnih krošenj s terenskim popisom je zamudna in zahteva veliko dela na lokacijah, zato so bile označitve podatkov narejene daljinsko. Anotacija je potekala z orodjem CVAT [5].


¹<https://clss.si>



Slika 4.1: Obarvan VMK glede na višino krošje v posameznem pikslu (levo) in popolni ortofoto (desno).

Označevanje posameznih dreves smo naredili na predpripravljenih slikah POF v kombinaciji z barvno sliko VMK. Postopek generacije takih slik je bil sledeč. S portala smo naložili digitalni model površja, digitalni model reliefa in popolni ortofoto za posamezne regije v velikosti 1 km^2 . Iz DMP in DMR smo ustvarili NOT, ki je vseboval $18\text{--}24 \text{ točk}/\text{m}^2$. POF in NOT smo razrezali na posamezne dele v velikosti 100 m^2 , saj bi bili drugače podatki preveliki za označevanje. Nato smo ustvarili VMK z ločljivostjo $0.16 \text{ m}/\text{piksel}$ in POF in VMK istega območja združili v eno sliko s prosojnostjo sloja VMK, kar omogoča prekrivanje višinskih podatkov z barvno sliko POF. To nam je omogočilo lažjo in bolj zanesljivo anotacijo dreves. Posamezna drevesa smo označili s parom označb. S točkami smo označili pozicijo debla drevesa. Krošnje posameznih dreves smo označili na dva načina, in sicer z elipso in z bitno masko. Za označitve krošenj z bitno masko smo si pomagali z modelom SegmentAnything [13].

Ko je bilo označevanje slik končano, smo bitne maske označenih krošenj pretvorili v georeferencirane poligone. To nam je omogočilo analizo in predstavitev rezultatov segmentacije.



Slika 4.2: Slika prikazuje oblak točk DMP, VMK in DMR od zgoraj navzdol.

Segmentacijo smo opravili na 1321 drevesih iz 8 območij v velikosti 100 m^2 . Sestoj področja smo ugotovili s pomočjo pregledovalnika Zavod za gozdove Slovenije (ZGS)². Sestoj zajetih podatkov je naveden v tabeli 4.1.

²<https://prostor.zgs.gov.si/pregledovalnik/>

Tabela 4.1: Sestava drevesnih vrst območja s pripadajočimi kokdami ZGS

Drevesna vrsta	koda ZGS	Glavne vrste [%]	Mladje [%]
Smreka	lzkdv11	83.62	58.76
Jelka	lzkdv21	8.59	19.46
Bor	lzkdv30	0.00	0.00
Macesen	lzkdv34	1.38	0.00
Ostali iglavci	lzkdv39	0.00	0.00
Bukev	lzkdv41	3.47	18.95
Hrasti	lzkdv50	0.00	0.00
Plemeniti listavci	lzkdv60	2.89	2.83
Trdi listavci	lzkdv70	0.00	0.00
Mehki listavci	lzkdv80	0.05	0.00

Poglavje 5

Rezultati

Predstavljen model SegmentAnyTree 3.2 in referenčni model 3.3 smo ocenili podlagi naših podatkov ter ju primerjali, glede na naslednje metrike vrednotenja.

5.1 Metrike za oceno uspešnosti metod

Za vrednotenje obeh pristopov segmentacije smo uporabili najpogostejše metrike uporabljene za nalogo SPD: pozitivna napovedna vrednost ali natančnost (angl. Positive predictive value, PPV), stopnja lažno negativnih primerkov (angl. False negative rate, FNR), stopnja lažnih odkritij (angl. False discovery rate, FDR) in občutljivost ali stopnja pozitivnih primerkov (angl. True positive rate, TPR).

Ena od metrik, ki smo je uporabili, je tudi Intersection over Union (IoU), ki meri stopnjo prekrivanja med napovedano in referenčno (dejansko) obliko objekta:

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

kjer je:

- A – množica pikslov, ki pripadajo napovedanemu segmentu (predicted object),
- B – množica pikslov, ki pripadajo zlatemu standardu (ground truth object).

S PP definirajmo število pravilno pozitivnih primerkov (dreves, ki jih je metoda uspešno segmentirala), z NN število napačnih negativnih primerkov (dreves, ki jih metoda ni zaznala) in z NP število napačno pozitivnih primerkov (dreves, ki jih je metoda zaznala napačno). Definirajmo nekaj meril.

Definicije meril

- **Natančnost:** delež pravilno zaznanih objektov glede na vse napovedi objektov.

$$\text{Natančnost} = \frac{PP}{PP + NP}$$

- **FNR:** delež objektov, ki jih model ni zaznal, glede na vse dejanske objekte.

$$\text{FNR} = \frac{NN}{PP + NN}$$

- **FDR:** delež napačno zaznanih objektov glede na vse napovedane objekte.

$$\text{FDR} = \frac{NP}{PP + NP}$$

- **F1 rezultat:** harmonično povprečje občutljivosti in natančnosti.

$$F1 = 2 \cdot \frac{\text{Natančnost} \cdot \text{Občutljivost}}{\text{Natančnost} + \text{Občutljivost}}$$

kjer je

$$\text{občutljivost} = \frac{PP}{PP + NN}$$

- **RMSE razdalje (m)**: koren srednje kvadratne napake razdalje napovedanega debla od dejanskega debla drevesa,

$$RMSE_d = \sqrt{\frac{1}{PP} \sum_{i=1}^{PP} d_i^2}$$

kjer je d_i razdalja od debla dejanskega drevesa do predikcije debla drevesa pravilne segmentacije.

V tabeli 5.1 so predstavljene metrične ocene uspešnosti za različne metode označb in napovedi.

Metodo PyCrown in SAT smo ocenili na zlatem standardu (angl. ground truth) krožnic in mask, ki jih je generiral model za segmentacijo slik SegmentAnything [13].


Napoved metode smo ocenili kot pravilno, če je bila napoved debla drevesa od dejanskega debla oddaljena manj kot 4.8 m, kar je ustrezalo 30 pikslom. Ker metoda SAT v svoji implementaciji ne napove debla drevesa, smo kot referenco za napoved uporabili središče poligona, ki predstavlja drevesno krošnjo.

Metoda anotacije	Metoda napovedi	Povprečni IoU	$RMSE_d$ (m)	Natančnost	FNR	FDR	F1 rezultat
ellipse	Pycrown	0.4890	2.380	0.7692	0.0840	0.2308	0.8276
	SAT	0.4698	2.790	0.6388	0.0519	0.3612	0.7540
SAM	Pycrown	0.4187	2.617	0.7769	0.0941	0.2231	0.8294
	SAT	0.4141	2.810	0.6395	0.0689	0.3605	0.7479

Tabela 5.1: Metrične ocene uspešnosti za različne metode anotacije in napovedi.

Rezultati kažejo, da je referenčna metoda segmentacijo (PyCrown) opravila bolje kot metoda SegmentAnyTree. Metoda SAT dosega najnižji FNR, kar je posledica preveliko segmentiranih dreves, saj je FDR pri njej večji. Rezultat F1 je večji pri referenčni metodi, kar kaže na to, da je metoda SAT vrnila slabše rezultate. To ni presenetljivo, saj smo za samo označevanje zlatega standarda uporabljali podobno rasterizirano sliko, kot jo uporablja referenčna metoda za samo segmentacijo dreves. Metoda označevanja ni

omogočala dovolj natančnosti, kar je vplivalo na uspešnost uporabljenih pristopov.



Slika 5.1: Segmentacija drevesa metode SAT (levo) in metode PyCrown (desno).


5.2 Razprava

Rezultati kažejo, da metoda PyCrown dosega boljše rezultate za skoraj vse izbrane metrike uspešnosti. Kot smo že omenili, je eden od razlogov način označevanja. V nadaljevanju bomo prikazali nekaj primerov, ki razlagajo dobljene rezultate.

Najprej si pogledjmo primer dobre in slabe segmentacije obeh metod na posameznih drevesih. Na sliki 5.1 je prikazan primer dobre segmentacije metode SAT (levo) in metode PyCrown (desno). To je primer osamljenega iglavca. Metodi sta pri segmentaciji osamljenih dreves natančni.


Naslednja slika 5.2 prikazuje segmentacijo drevesa nižje rasti z metodo SAT (levo) in metodo PyCrown (desno). Točke, ki pripadajo istemu drevesu, dobijo enako enolično oznako in so zato prikazane v isti barvi. Na desni sliki so točke enega drevesa pobarvane različno. To pomeni, da je metoda PyCrown eno drevo označila kot tri različna drevesa. Z uravnavanjem parametrov metode bi to lahko popravili, ampak bi s tem žrtvovali pravilno segmentacijo ostalih dreves.

Na sliki 5.3 je prikazana napačna segmentacija metode SAT (levo) in



Slika 5.2: Primer pravilne segmentacije metode SAT (levo) in napačne segmentacije metode PyCrown (desno). Točke enega drevesa so obarvane z isto barvo.


pravilna segmentacija metode PyCrown (desno). Nadsegmentacija velikih dreves je za metodo SAT pogosta. Vzrok za nadsegmentacijo je lahko redek oblak točk ali merilna napaka. [h]



Slika 5.3: Primer nadsegmentacije metode SAT (levo) in segmentacije metode PyCrown (desno).

Pri ročni analizi rezultatov smo zasledili tudi primere, kjer model SAT gručo dreves segmentira bolje, kot smo to opravili z ročnim označevanjem. To smo prikazali na sliki 5.4.


Na levi sliki so prikazane segmentacije modela in naše oznake. Z rdečo barvo smo označili napačne napovedi metode. Desna slika prikazuje ustrezen del oblaka točk leve strani. Vidimo, da je model segmentiral tri drevesa. Pri označevanju podatkov to ni bilo očitno, vendar iz oblike oblaka točk lahko sklepamo, da je metoda SAT obkrožena drevesa segmentirala pravilno.



Slika 5.4: Primer, kjer je segmentacija modela boljša od zlatega standarda.

Slika 5.5 prikazuje, kako metoda PyCrown segmentira isto gručo dreves. Na levi sliki lahko vidimo, da je metoda segmentirala tri drevesa, vendar se krošnji dominantnih dreves v napovedi močno prekrivata. Takšne napovedi so nezaželene, saj lahko iz takih podatkov precenimo gozdnatost nekega območja. Metoda tretje drevo segmentira delno. Vidimo lahko, da je del krošnje obarvan v enaki barvi kot točke tal, kar pomeni, da ni pravilno segmentiral celotne krošnje.


Označevanje nizkih dreves in dreves v podrasti je bil glavni razlog nestrinjanja metod z zlatim standardom. Na sliki 5.6 je prikazano, kako sta metodi segmentirali gručo dreves nizke rasti. Na oblaku točk smo opazili, da so krošnje pri oblaku točk segmentiranim z modelom SAT bolj naravnih




Slika 5.5: Primer segmentacije referenčne metode.

oblik (desno zgoraj). Na slikah označb in napovedi (spodaj) smo opazili, da je segmentacija modela SAT bolj smiselna glede na oblak točk. O pravilnosti segmentacije žal ne moremo govoriti, saj nam metoda označevanja ni dopuščala z natančnostjo oceniti nizkih dreves.

Pomembna razlika med metodama je oblika napovedi. Metoda PyCrown jih poda v obliki poligonov, medtem ko metoda SAT za vsako točko v oblaku točk napove pripadnost drevesu. Za oceno IoU smo iz segmentiranih točk metode SAT generirali poligone (konveksna ovojnica), ki smo jih primerjali z našimi oznakami. Metrika povprečnega deleža IoU je pokazala, da metoda PyCrown bolje napove velikost krošnje drevesa. Rezultat je posledica načina označevanja. Spomnimo se, da smo podatke označevali na osnovi VMK in ortofoto posnetkov. Oznake so temeljile na informacijah, ki nam jih ponuja VMK. Menimo, da je rezultat metrike v okviru tega dela brezpredmeten. Na sliki 5.7 je prikazan primer oznak za vse metode označevanja in napovedi. Oznake so rdeče, metode napovedi so modre barve.




Slika 5.6: Primerjava segmentacije dreves nizke rasti metode PyCrown (levo) in metode SAT (desno).



Slika 5.7: Primer prekrivanja oznak (rdeča barva) in napovedi (modra barva): metoda oznak SAM in metoda napovedi PyCrown (zgoraj levo), metoda oznak SAM in metoda napovedi SAT (zgoraj desno), metoda oznak elipse in metoda napovedi PyCrown (spodaj levo), metoda oznak elipse in metoda napovedi SAT (spodaj desno).

Metoda SegmentAnyTree je v gostejših gozdovih dosegla boljše rezultate. Z grafom 5.8 smo predstavili, FNR v odvisnosti od gostote gozda. Gostoto smo predstavili kot povprečje razdalj najbližjega sosednjega drevesa za vsako območje obravnav. Z grafa lahko odčitamo, da se razlika med številom takih dreves z gostoto gozda večja. To pomeni, da je metoda SAT bolj primerna za segmentiranje gostejših gozdov.



Slika 5.8: Graf FNR v odvisnosti od gostote gozda.

Na podlagi teh primerov trdimo, da metrike za ocenjevanje segmentacije niso dober pokazatelj uspešnosti metode SAT. Kljub našemu pristopu smo na nekaj primerih uspeli pokazati, da metoda SAT v primerjavi z metodo PyCrown dobro segmentira nizka drevesa in goste pretežno iglaste gozdove. Za oceno robustnosti metode bi bile potrebne dodatne raziskave na različnih tipih gozdov, pri čemer bi bil potreben daljši časovni okvir.

Poglavje 6

Zaključek

Razvoj globokih nevronske mreže na volumetričnih podatkih je vzbudil ponoven interes za poskus segmentacije posameznih dreves. Pristop z nevronskimi mrežami je pokazal velik potencial, a je odvisen od kakovosti zajetih podatkov. Model, uporabljen v diplomski nalogi, smo primerjali z referenčnim algoritmom, ki temelji na že razvitih metodah za segmentacijo posameznih dreves.

Rezultati so pokazali, da model SAT lahko konkurira referenčni metodi. Pokazali smo, da je primernejši za segmentacijo gozdov, kjer je veliko dreves nižje rasti. Metoda se je izkazala za učinkovitejšo tudi v gostejše poraščenih iglastih gozdovih. Prav tako smo pokazali potencial metode na oblakih točk z manjšo gostoto. Ena od prednosti metode SAT je tudi ta, da za samo segmentacijo ne potrebujemo predpriprave podatkov, ampak metoda deluje brez dodatnega predprocesiranja. To dokazuje, da je uporabljena metoda enostavna za uporabo in je primerna za pregled gozdnih virov. Boljšo oceno kakovosti napovedi pa bi bilo potrebno dodatno raziskati.

V nadaljevanju raziskav je pomembno, da se metoda oceni na bolj temeljiti množici označenih podatkov. Metoda deluje tudi na podatkih nekoliko slabše kakovosti, kar zmanjšuje zahtevnost procesiranja in nam omogoča uporabo računsko zahtevnejših arhitektur nevronske mreže. V nadaljevanju želimo izboljšati delovanje metode z učenjem nevronske mreže na naših

podatkih.

Kakovostna metoda segmentacije posameznih dreves nam bo omogočala boljše ocenjevanje biomase in ogljičnega skladiščenja. Omogočila bo sledenje rasti dreves in identifikacijo bolnih dreves, kar predstavlja pomemben doprinos naravoslovni in gozdarski panogi.

Literatura

- [1] Voxel vs point based approaches in 3d deep learning: Who wins a fight? <https://www.thinkautonomous.ai/blog/voxel-vs-points/>. Accessed: 2025-08-28.
- [2] Elias Ayrey, Shawn Fraver, John A. Kershaw Jr., Laura S. Kenefic, Daniel Hayes, Aaron R. Weiskittel, and Brian E. Roth. Layer stacking: A novel algorithm for individual forest tree segmentation from lidar point clouds. *Canadian Journal of Remote Sensing*, 43(1):16–27, 2017. doi: 10.1080/07038992.2017.1252907. URL <https://doi.org/10.1080/07038992.2017.1252907>.
- [3] Yujie Cao, James GC Ball, David A Coomes, Leon Steinmeier, Nikolai Knapp, Phil Wilkes, Mathias Disney, Kim Calders, Andrew Burt, Yi Lin, et al. Benchmarking airborne laser scanning tree segmentation algorithms in broadleaf forests shows high accuracy only for canopy trees. *International Journal of Applied Earth Observation and Geoinformation*, 123:103490, 2023.
- [4] Qi Chen, Dennis Baldocchi, Peng Gong, and Maggi Kelly. Isolating individual trees in a savanna woodland using small footprint lidar data. *Photogrammetric Engineering & Remote Sensing*, 72(8):923–932, 2006.
- [5] CVAT.ai Corporation. Computer vision annotation tool (cvat), 2023. URL <https://cvat.ai/>.
- [6] Michele Dalponte and David A. Coomes. Tree-centric mapping of fo-

- rest carbon density from airborne laser scanning and hyperspectral data. *Methods in Ecology and Evolution*, 7(10):1236–1245, 2016. doi: <https://doi.org/10.1111/2041-210X.12575>. URL <https://besjournals.onlinelibrary.wiley.com/doi/abs/10.1111/2041-210X.12575>.
- [7] Tianyang Dong, Xinpeng Zhang, Zhanfeng Ding, and Jing Fan. Multi-layered tree crown extraction from lidar data using graph-based segmentation. *Computers and Electronics in Agriculture*, 170:105213, 2020. ISSN 0168-1699. doi: <https://doi.org/10.1016/j.compag.2020.105213>. URL <https://www.sciencedirect.com/science/article/pii/S0168169919316874>.
- [8] Lothar Eysn, Markus Hollaus, Eva Lindberg, Frédéric Berger, Jean-Matthieu Monnet, Michele Dalponte, Milan Kobal, Marco Pellegrini, Emanuele Lingua, Domen Mongus, and Norbert Pfeifer. A benchmark of lidar-based single tree detection methods using heterogeneous forest data from the alpine space. *Forests*, 6(5):1721–1747, 2015. ISSN 1999-4907. doi: [10.3390/f6051721](https://doi.org/10.3390/f6051721). URL <https://www.mdpi.com/1999-4907/6/5/1721>.
- [9] François A Gougeon and Donald G Leckie. The individual tree crown approach applied to ikonos images of a coniferous plantation area. *Photogrammetric Engineering & Remote Sensing*, 72(11):1287–1297, 2006.
- [10] Jonathan Henrich, Jan van Delden, Dominik Seidel, Thomas Kneib, and Alexander S. Ecker. Treelearn: A deep learning method for segmenting individual trees from ground-based lidar forest point clouds. *Ecological Informatics*, 84:102888, 2024. ISSN 1574-9541. doi: <https://doi.org/10.1016/j.ecoinf.2024.102888>. URL <https://www.sciencedirect.com/science/article/pii/S1574954124004308>.
- [11] Marek K. Jakubowski, Wenkai Li, Qinghua Guo, and Maggi Kelly. Delineating individual trees from lidar data: A comparison of vector-

- and raster-based segmentation approaches. *Remote Sensing*, 5(9):4163–4186, 2013. ISSN 2072-4292. doi: 10.3390/rs5094163. URL <https://www.mdpi.com/2072-4292/5/9/4163>.
- [12] Harri Kaartinen, Juha Hyypä, Xiaowei Yu, Mikko Vastaranta, Hannu Hyypä, Antero Kukko, Markus Holopainen, Christian Heipke, Manuela Hirschmugl, Felix Morsdorf, Erik Næsset, Juho Pitkänen, Sorin Popescu, Svein Solberg, Bernd Michael Wolf, and Jee-Cheng Wu. An international comparison of individual tree detection and extraction using airborne laser scanning. *Remote Sensing*, 4(4):950–974, 2012. ISSN 2072-4292. doi: 10.3390/rs4040950. URL <https://www.mdpi.com/2072-4292/4/4/950>.
- [13] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything, 2023. URL <https://arxiv.org/abs/2304.02643>.
- [14] Juheon Lee, David Coomes, Carola-Bibiane Schonlieb, Xiaohao Cai, Jan Lellmann, Michele Dalponte, Yadvinder Malhi, Nathalie Butt, and Mike Morecroft. A graph cut approach to 3d tree delineation, using integrated airborne lidar and hyperspectral imagery, 2017. URL <https://arxiv.org/abs/1701.06715>.
- [15] Kaisen Ma, Zhenxiong Chen, Liyong Fu, Wanli Tian, Fugen Jiang, Jing Yi, Zhi Du, and Hua Sun. Performance and sensitivity of individual tree segmentation methods for uav-lidar in multiple forest types. *Remote Sensing*, 14(2), 2022. ISSN 2072-4292. doi: 10.3390/rs14020298. URL <https://www.mdpi.com/2072-4292/14/2/298>.
- [16] Zhenyu Ma, Yong Pang, Di Wang, Xiaojun Liang, Bowei Chen, Hao Lu, Holger Weinacker, and Barbara Koch. Individual tree crown segmentation of a larch plantation using airborne laser scanning data based on region growing and canopy morphology features. *Remote Sen-*

- sing*, 12(7), 2020. ISSN 2072-4292. doi: 10.3390/rs12071078. URL <https://www.mdpi.com/2072-4292/12/7/1078>.
- [17] Javier Marcello, María Spínola, Laia Albors, Ferran Marqués, Dionisio Rodríguez-Esparragón, and Francisco Eugenio. Performance of individual tree segmentation algorithms in forest ecosystems using uav lidar data. *Drones*, 8(12), 2024. ISSN 2504-446X. doi: 10.3390/drones8120772. URL <https://www.mdpi.com/2504-446X/8/12/772>.
- [18] Sungchan Oh, Jinha Jung, Guofan Shao, Gang Shao, Joey Gallion, and Songlin Fei. High-resolution canopy height model generation and validation using usgs 3dep lidar data in indiana, usa. *Remote Sensing*, 14(4), 2022. ISSN 2072-4292. doi: 10.3390/rs14040935. URL <https://www.mdpi.com/2072-4292/14/4/935>.
- [19] J Pitkänen, M Maltamo, J Hyyppä, and X Yu. Adaptive methods for individual tree detection on airborne laser based canopy height model. *International Archives of Photogrammetry, Remote Sensing and Spatial Information Sciences*, 36(8):187–191, 2004.
- [20] Juho Pitkänen. Individual tree detection in digital aerial images by combining locally adaptive binarization and local maxima methods. *Canadian Journal of Forest Research*, 31(5):832–844, 2001. doi: 10.1139/x01-013. URL <https://doi.org/10.1139/x01-013>.
- [21] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation, 2015. URL <https://arxiv.org/abs/1505.04597>.
- [22] Vito Rozman. *Konvolucijske nevronske mreže in njihova uporaba: delo diplomskega seminarja*. PhD thesis, Fakulteta za matematiko in fiziko, Univerza v Ljubljani, 2022. URL <https://repozitorij.uni-lj.si/IzpisGradiva.php?lang=slv&id=140493>.

-
- [23] Yongwei Sheng, P Gong, and GS Biging. Model-based conifer-crown surface reconstruction from high-resolution aerial images. *Photogrammetric engineering and remote sensing*, 2001.
- [24] David E. Smith, Maria T. Zuber, Herbert V. Frey, James B. Garvin, James W. Head, Duane O. Muhleman, Gordon H. Pettengill, Roger J. Phillips, Sean C. Solomon, H. Jay Zwally, W. Bruce Banerdt, Thomas C. Duxbury, Matthew P. Golombek, Frank G. Lemoine, Gregory A. Neumann, David D. Rowlands, Oded Aharonson, Peter G. Ford, Anton B. Ivanov, Catherine L. Johnson, Patrick J. McGovern, James B. Abshire, Robert S. Afzal, and Xiaoli Sun. Mars orbiter laser altimeter: Experiment summary after the first year of global mapping of mars. *Journal of Geophysical Research: Planets*, 106(E10):23689–23722, 2001. doi: <https://doi.org/10.1029/2000JE001364>. URL <https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2000JE001364>.
- [25] Thomas Stegmüller, Behzad Bozorgtabar, Antoine Spahr, and Jean-Philippe Thiran. Scorenet: Learning non-uniform attention and augmentation for transformer-based histopathological image classification, 2022. URL <https://arxiv.org/abs/2202.07570>.
- [26] Jari Vauhkonen, Liviu Ene, Sandeep Gupta, Johannes Heinzl, Johan Holmgren, Juho Pitkänen, Svein Solberg, Yunsheng Wang, Holger Weinacker, K Marius Hauglin, et al. Comparative testing of single-tree detection algorithms under different types of forest. *Forestry*, 85(1): 27–40, 2012.
- [27] Le Wang, Peng Gong, and Gregory S. Biging. Individual tree-crown delineation and treetop detection in high-spatial-resolution aerial imagery. *Photogrammetric Engineering Remote Sensing*, 70(3):351–357, 2004. ISSN 0099-1112. doi: [doi:10.14358/PERS.70.3.351](https://doi.org/10.14358/PERS.70.3.351). URL <https://www.ingentaconnect.com/content/asprs/pers/2004/00000070/00000003/art00007>.

-
- [28] Maciej Wielgosz, Stefano Puliti, Binbin Xiang, Konrad Schindler, and Rasmus Astrup. Segmentanytree: A sensor and platform agnostic deep learning model for tree segmentation using laser scanning data. *Remote Sensing of Environment*, 313:114367, 2024. ISSN 0034-4257. doi: <https://doi.org/10.1016/j.rse.2024.114367>. URL <https://www.sciencedirect.com/science/article/pii/S0034425724003936>.
- [29] Binbin Xiang, Torben Peters, Theodora Kontogianni, Frawa Vetterli, Stefano Puliti, Rasmus Astrup, and Konrad Schindler. Towards accurate instance segmentation in large-scale lidar point clouds, 2023. URL <https://arxiv.org/abs/2307.02877>.
- [30] Xin Xu, Federico Iuricich, Kim Calders, John Armston, and Leila De Floriani. Topology-based individual tree segmentation for automated processing of terrestrial laser scanning point clouds. *International Journal of Applied Earth Observation and Geoinformation*, 116:103145, 2023. ISSN 1569-8432. doi: <https://doi.org/10.1016/j.jag.2022.103145>. URL <https://www.sciencedirect.com/science/article/pii/S1569843222003338>.
- [31] Juntao Yang, Zhizhong Kang, Sai Cheng, Zhou Yang, and Perpetual Hope Akwensi. An individual tree segmentation method based on watershed algorithm and three-dimensional spatial distribution analysis from airborne lidar point clouds. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 13:1055–1067, 2020. doi: 10.1109/JSTARS.2020.2979369.
- [32] Xiaowei Yu, Juha Hyypä, Mikko Vastaranta, Markus Holopainen, and Risto Viitala. Predicting individual tree attributes from airborne laser point clouds based on the random forests technique. *ISPRS Journal of Photogrammetry and remote sensing*, 66(1):28–37, 2011.
- [33] Cailian Zhang, Chengwen Song, Aleksandra Zaforemska, Jiaxing Zhang, Rachel Gaulton, Wenxia Dai, and Wen Xiao. Individual tree segmenta-

tion from uas lidar data based on hierarchical filtering and clustering. *International Journal of Digital Earth*, 17(1):2356124, 2024. doi: 10.1080/17538947.2024.2356124. URL <https://doi.org/10.1080/17538947.2024.2356124>.